MBA-6005 TRAVAIL INDIVIDUEL 02

Zouheyr Ayas

Nov 15, 2020

Contents

PLAN DE TRAVAIL	1
PRATIQUE - PARTIE 01	1
Chargement de données	1
Exploration de la structure de données	2
QUESTION 01: Nombre d'hommes et de femmes par grade	2
QUESTION 02 : Histogramme pour les années de service $\ \ldots \ \ldots \ \ldots \ \ldots$	3
QUESTION 03 : Dessiner un box plot pour le salaire	4
QUESTION 04: Dessiner un box plot pour le salaire par grade	5
EXPREMENTATIONS:	7
3.2.RELATION ENTRE LES VARIABLES	7
PRATIQUE - PARTIE 02	21
PRATIQUE - PARTIE 02 Chargement de données	
•	21
Chargement de données	21 21
Chargement de données	21 21 23
Chargement de données	21 21 23
Chargement de données	21 21 23

Loading required package: carData

library(car)

```
data(Salaries)
head(Salaries, 10)
           rank discipline yrs.since.phd yrs.service
                                                        sex salary
##
## 1
           Prof
                         В
                                      19
                                                   18
                                                        Male 139750
## 2
           Prof
                         В
                                      20
                                                   16
                                                        Male 173200
## 3
      AsstProf
                         В
                                       4
                                                   3
                                                        Male 79750
## 4
           Prof
                         В
                                      45
                                                   39
                                                        Male 115000
                                                        Male 141500
## 5
           Prof
                         В
                                      40
                                                   41
## 6 AssocProf
                         В
                                       6
                                                   6
                                                        Male 97000
## 7
           Prof
                         В
                                      30
                                                   23
                                                        Male 175000
## 8
          Prof
                         В
                                      45
                                                   45
                                                        Male 147765
## 9
           Prof
                         В
                                      21
                                                   20
                                                        Male 119250
## 10
           Prof
                         В
                                                   18 Female 129000
                                      18
```

Exploration de la structure de données

QUESTION 01: Nombre d'hommes et de femmes par grade

```
##
## Female Male
## AsstProf 11 56
## AssocProf 10 54
## Prof 18 248
```

Proportions d'hommes et de femmes par grade:

```
prop.table(table(Salaries$rank,Salaries$sex))
```

Proportion globale:

```
prop.table(table(Salaries$rank,Salaries$sex),1)
```

Proportion par ligne:

```
prop.table(table(Salaries$rank,Salaries$sex),2)
```


Proportion par colonne:

QUESTION 02 : Histogramme pour les années de service

```
hist(Salaries$yrs.service, freq = FALSE,
    main="Années de service - Densité",col="lightgreen",
    xlab = "Années de services",probability = TRUE,
    labels = TRUE)

#Dessiner la ligne de densité
lines(density(Salaries$yrs.service, bw=10),type="l",col="darkred",lwd=5)
```


Années de service - Densité



QUESTION 03 : Dessiner un box plot pour le salaire


boxplot(Salaries\$salary, col="lightblue",main="Salaire",ylab="\$\$\$")

Salaire




QUESTION 04: Dessiner un box plot pour le salaire par grade

Les salaires par grade



Plot de salaires par Sex:

Les salaires par sex



EXPREMENTATIONS:

3.2.RELATION ENTRE LES VARIABLES

3.2.1.Chargement de données de CRM

```
cust.df<-read.csv("http://goo.gl/PmPkaG")
str(cust.df)</pre>
```

```
'data.frame':
                    1000 obs. of 12 variables:
    $ cust.id
                               1 2 3 4 5 6 7 8 9 10 ...
##
                               22.9 28 35.9 30.5 38.7 ...
    $ age
                        : num
                               631 749 733 830 734 ...
    $ credit.score
                        : num
                               "yes" "yes" "yes" "yes" ...
##
    $ email
                        : chr
    $ distance.to.store: num
                               2.58 48.18 1.29 5.25 25.04 ...
                               20 121 39 1 35 1 1 48 0 14 ...
##
    $ online.visits
                        : int
    $ online.trans
##
                               3 39 14 0 11 1 1 13 0 6 ...
                        : int
                               58.4 756.9 250.3 0 204.7 ...
##
    $ online.spend
                        : num
    $ store.trans
                               4 0 0 2 0 0 2 4 0 3 ...
                        : int
    $ store.spend
                        : num
                               140.3 0 0 95.9 0 ...
    $ sat.service
                        : int
                               3 3 NA 4 1 NA 3 2 4 3 ...
                        : int \mbox{3 3 NA 2 1 NA 3 3 2 2} \dots
    $ sat.selection
```

3.2.2. Converting data to factors

```
str(cust.df$cust.id)


## int [1:1000] 1 2 3 4 5 6 7 8 9 10 ...

cust.df$cust.id<-factor(cust.df$cust.id)

str(cust.df$cust.id)

## Factor w/ 1000 levels "1","2","3","4",...: 1 2 3 4 5 6 7 8 9 10 ...


plot(x=cust.df$age,y=cust.df$credit.score,xlab = "AGE", ylab = "CREDIT")</pre>
```



3.2.3. Add color, labels, and adjust axis limits

```
plot(cust.df$age, cust.df$credit.score,col="orange",xlim=c(15,55),
    ylim = c(500,900),main="Clients actifs en juin 2014",
    xlab = "Age du client(Années)",ylab = "Cote de crédit")
```


Clients actifs en juin 2014




3.2.4. Regression

```
plot(cust.df$age, cust.df$credit.score,col="orange",xlim=c(15,55),
    ylim = c(500,900),main="Clients actifs en juin 2014",
    xlab = "Age du client(Années)",ylab = "Cote de crédit")
abline(lm(cust.df$credit.score ~ cust.df$age),col="red")
```

Clients actifs en juin 2014




3.2.5. Ventes en ligne vs ventes en magasin



${\bf 3.2.6.} {\bf Histogramme}$ des depenses en magasin:


```
hist(cust.df$store.spend,
    breaks=(0:ceiling(max(cust.df$store.spend)/10))*10,
    xlab = "Vente en ligne sur une année")
```

Histogram of cust.df\$store.spend




3.2.7.Utilisation de la fonction logarithmique

```
plot(cust.df$store.spend+1,cust.df$online.spend+1,log = "xy")
```




3.2.8.Multi-panel plot

```
par(mfrow=c(2, 2))
with(cust.df, plot(distance.to.store, store.spend))
with(cust.df, plot(distance.to.store, online.spend))
with(cust.df, plot(distance.to.store, store.spend+1, log="xy"))
with(cust.df, plot(distance.to.store, online.spend+1, log="xy"))
```



3.2.9.ScatterPlot Matrix


```
pairs(formula = ~ age + credit.score + distance.to.store +
online.spend + store.trans + store.spend, data=cust.df,lower.panel=panel.smooth,col="lightblue")
```



3.2.10.ScatterPlot Matrix with car data

```
library(car)
scatterplotMatrix(formula = ~ age + credit.score +
distance.to.store + online.spend + store.trans +
store.spend, data=cust.df, diagonal="histogram")

## Warning in applyDefaults(diagonal, defaults = list(method =
## "adaptiveDensity"), : unnamed diag arguments, will be ignored
```



3.2.11. Coefficient de correlation de Pearson

```
cor(cust.df$age,cust.df$credit.score)
```

[1] 0.2545045

3.2.12. Matrice de correlation

```
cor(cust.df[, c(2, 3, 5:12)])
```

```
##
                              age credit.score distance.to.store online.visits
## age
                      1.00000000 0.254504457
                                                       0.00198741
                                                                    -0.06138107
## credit.score
                      0.254504457 1.000000000
                                                      -0.02326418
                                                                    -0.01081827
## distance.to.store 0.001987410 -0.023264183
                                                       1.00000000
                                                                    -0.01460036
## online.visits
                     -0.061381070 -0.010818272
                                                      -0.01460036
                                                                     1.00000000
## online.trans
                     -0.063019935 -0.005018400
                                                      -0.01955166
                                                                     0.98732805
## online.spend
                     -0.060685729 -0.006079881
                                                      -0.02040533
                                                                     0.98240684
## store.trans
                      0.024229708 0.040424158
                                                      -0.27673229
                                                                    -0.03666932
                      0.003841953 0.042298123
                                                      -0.24149487
                                                                    -0.05068554
## store.spend
## sat.service
                               NA
                                                               NA
                                                                             NA
                               NA
                                            NA
                                                               NA
                                                                             NA
## sat.selection
```


```
##
                   online.trans online.spend store.trans store.spend
## age
                    -0.06301994 -0.060685729 0.02422971 0.003841953
                    -0.00501840 -0.006079881 0.04042416 0.042298123
## credit.score
## distance.to.store -0.01955166 -0.020405326 -0.27673229 -0.241494870
                     ## online.visits
## online.trans
                     1.00000000 0.993346657 -0.04024588 -0.052244650
## online.spend
                     0.99334666 1.000000000 -0.04089133 -0.051690053
                    -0.04024588 -0.040891332 1.00000000 0.892756851
## store.trans
## store.spend
                    -0.05224465 -0.051690053 0.89275685 1.000000000
## sat.service
                             NA
                                                                 NA
                                         NA
                                                    NA
## sat.selection
                             NA
                                         NA
                                                    NA
                                                                 NA
                   sat.service sat.selection
##
## age
                            NA
                            NA
                                         NA
## credit.score
## distance.to.store
                            NA
                                         NA
## online.visits
                            NA
                                         NA
## online.trans
                            NA
                                         NA
## online.spend
                            NA
                                         NA
## store.trans
                            NA
                                         NA
## store.spend
                            NA
                                         NA
## sat.service
                             1
                                         NA
## sat.selection
                            NA
                                          1
```

3.2.13. Visualiser la matrice de corrélation

```
library(corrplot)
```

```
## corrplot 0.84 loaded
```

```
corrplot(corr=cor(cust.df[ , c(2, 3, 5:12)],
use="complete.obs"), method ="ellipse")
```



3.2.14. Transformation de données

[1] 0.4843334

```
cor(cust.df$distance.to.store, cust.df$store.spend)

## [1] -0.2414949


cor(1/cust.df$distance.to.store, cust.df$store.spend)

## [1] 0.4329997

cor(1/sqrt(cust.df$distance.to.store), cust.df$store.spend)
```

3.2.15. Exploration des associations dans des réponses d'enquête


```
plot (cust.df$sat.service, cust.df$sat.selection, xlab="Sat,
Service", ylab="Sat, Selection")
```



3.2.16.Exploration des associations dans des réponses d'enquête - suite

```
plot(jitter(cust.df$sat.service), jitter(cust.df$sat.selection),
xlab="Customer Satisfaction with Service",
ylab="Customer Satisfaction with Selection",
main="Customers as of June 2014")
```

Customers as of June 2014



3.2.17. Exploration des associations dans des réponses d'enquête - suite

```
resp <- !is.na(cust.df$sat.service)</pre>
library(psych)
##
## Attaching package: 'psych'
## The following object is masked from 'package:car':
##
##
       logit
polychoric(cbind(cust.df$sat.service[resp],
cust.df$sat.selection[resp]))
## Call: polychoric(x = cbind(cust.df$sat.service[resp], cust.df$sat.selection[resp]))
## Polychoric correlations
      C1
           C2
## R1 1.00
## R2 0.67 1.00
##
    with tau of
##
```

```
## 1 2 3 4
## [1,] -1.83 -0.72 0.54 1.7
## [2,] -0.99 0.12 1.26 2.4
```

PRATIQUE - PARTIE 02

Chargement de données


```
head(Salaries,10)
##
          rank discipline yrs.since.phd yrs.service
                                                     sex salary
                                                    Male 139750
## 1
          Prof
                       В
                                    19
## 2
                       В
                                    20
          Prof
                                                16
                                                    Male 173200
## 3
      AsstProf
                       В
                                    4
                                                3
                                                    Male 79750
## 4
          Prof
                       В
                                    45
                                                39
                                                    Male 115000
## 5
          Prof
                       В
                                    40
                                                41
                                                    Male 141500
                                                    Male 97000
## 6 AssocProf
                       В
                                    6
                                                6
## 7
          Prof
                       В
                                    30
                                                23
                                                    Male 175000
## 8
          Prof
                       В
                                    45
                                                45
                                                    Male 147765
                       В
                                    21
                                                20
                                                    Male 119250
## 9
          Prof
## 10
          Prof
                       В
                                    18
                                                18 Female 129000
```

QUESTION 01 : Les salaires par rapport aux années écoulées depuis le doctorat

```
logSalary <- log(Salaries$salary)

plot(Salaries$yrs.since.phd,Salaries$salary,
    main = "Salaires par rapport au nombre d'années apres le doctorat",
    xlab = "Temps aprés phd(année)",
    ylab = "salaires($)",
    col="red")</pre>
```


Salaires par rapport au nombre d'années apres le doctorat



Dessinons une droite sur le nuage de points

```
plot(Salaries$yrs.since.phd,Salaries$salary,
    main = "Salaires par rapport au nombre d'années aprés le doctorat",
    xlab = "Temps aprés phd(année)",
    ylab = "salaires($)",
    col="red")
model=lm(Salaries$salary ~ Salaries$yrs.since.phd)
abline(model,col="darkred")
```

Salaires par rapport au nombre d'années aprés le doctorat



QUESTION 02 : Corrélation entre salaire et nombre d'années aprés le doctorat

Il parait qu'il y a une linéarité entre les deux variables, Salaires et nombre d'années après le doctorat, calculons le coefficient de corrélation de Pearson pour bien évaluer le degré de dépendance

```
cor.test(Salaries$salary , Salaries$yrs.since.phd)
```


```
##
## Pearson's product-moment correlation
##
## data: Salaries$salary and Salaries$yrs.since.phd
## t = 9.1775, df = 395, p-value < 2.2e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## 0.3346160 0.4971402
## sample estimates:
## cor
## 0.4192311</pre>
```

Coefficient de Pearson = 0.42, la dépendance est considérée $\mathbf{mod\acute{e}r\acute{e}e}$

Corrélation entre la variable salaire et nombre d'années de service

```
plot(Salaries$yrs.service,Salaries$salary,
    main = "Salaires par rapport au nombre d'années de service",
    xlab = "Temps de service(année)",
    ylab = "salaires($)",
    col="blue")
model=lm(Salaries$salary ~ Salaries$yrs.service)
abline(model,col="darkblue")
```

Salaires par rapport au nombre d'années de service



Coefficient de corrélation

```
cor.test(Salaries$salary , Salaries$yrs.service)

##

## Pearson's product-moment correlation

##

## data: Salaries$salary and Salaries$yrs.service

## t = 7.0602, df = 395, p-value = 7.529e-12

## alternative hypothesis: true correlation is not equal to 0

## 95 percent confidence interval:

## 0.2443740 0.4193506
```

```
## sample estimates:
## cor
## 0.3347447
```


Coefficient de Pearson = 0.33, la dépendance est considérée faible

P-Value

On observe que dans les deux test le P-Value est de loins inférieur à 0.05, alors les résultats sont significatives statistiquement

QUESTION 03: Visualisation de toutes les relations bivariées

```
library(corrplot)
corrplot(corr=cor(Salaries[ , c(3, 4, 6)],
use="complete.obs"), method ="circle",
sig.level =0.05,insig = "blank",)
```



On observe une corrélation relativement faible entre la variable salaire et les deux autres variables "nombre d'années de service" et "nombre d'années écoulées après le doctorat.